

Análise da propagação de notícias falsas sobre COVID no Twitter

Lucas Freire
Giovani Valdrighi
Taisa Calvette

January 14, 2022

1 Notebook link:

Uma análise exploratória inicial foi realizada [neste notebook](#). Como achados iniciais encontramos razoável separação entre os tópicos em uma amostra dos dados.

2 Descrição

O objetivo principal do trabalho é o de construir uma visualização para analisar um conjunto de *tweets* sobre a pandemia de coronavírus que foram classificados pelo Aos Fatos, que é um jornal verificador de informações falsas. A visualização irá auxiliar na análise de como a narrativa dos perfis de desinformação se alterou ao longo do tempo, especificamente em relação ao COVID-19. O tema é de extrema relevância uma vez que foram disseminadas diversas *fake news* sobre a pandemia.

Será utilizado o paper de [2] como referência na apresentação final dos dados.

3 Background

O aumento de notícias falsas (*fake news*) está se tornando um problema mundial. Embora este não seja um problema recente, este vem se tornando um motivo de preocupação por causa da popularidade das redes sociais, que permitem a interação e difusão de notícias rapidamente e em grande escala. Por meio de compartilhamentos, curtidas ou retuítes, a informação falsa acaba se tornando incontável, altamente disseminada e de difícil localização da fonte. Desta forma, podemos dizer que as redes sociais se tornaram um lugar para divulgar informações e notícias falsas rapidamente. De fato o compartilhamento de notícias falsas tornou-se um galopante no mundo digital atual e se tornou também um incentivo para alguns indivíduos que se beneficiam com a proliferação de desinformação para um grande público.

Em dezembro de 2019, um novo vírus chamado COVID-19 foi relatado na China e, nos últimos meses, o vírus se espalhou para outras partes do mundo, levando muitas pessoas a óbito. Inicialmente, foi alegado que era transmitido de animais para humanos. No entanto, agora é transmitido de humanos para humanos por meio de contatos e gotículas. Em meio a incertezas e desconhecimento, muitos rumores e notícias falsas começaram a circular sobre o COVID-19. Consequentemente, a desinformação nas redes sociais alimentou o pânico entre o público em relação à pandemia COVID-19. O fato é que vem se tornando cada vez mais difícil distinguir notícias falsas de reportagens fidedignas. Neste contexto específico de notícias falsas de COVID-19, alguns autores vem fazendo a análise de redes sociais.

Apuke et. al (2021) usou a análise para entender a motivação por trás das *fake news* através do modelo *Use and Gratification Framework*. Os dados foram analisados com *Partial Least Squares* (PLS) para determinar os efeitos de seis variáveis no resultado do compartilhamento de notícias falsas. Os resultados encontrados pelos autores mostraram que o altruísmo foi o fator mais significativo que previu o compartilhamento de notícias falsas do COVID-19 [1].

Moscadelli et. al (2020) realizou a análise com o objetivo de medir quantas notícias falsas e as notícias verificadas correspondentes circularam na Itália no período entre 31 de dezembro de 2019 e 30 de abril de 2020. Os autores encontraram que os links que continham notícias falsas foram compartilhados 2.352.585 vezes, representando 23,1% do total de compartilhamentos de todos os artigos analisados. O que mostra como é preocupante a disseminação de *fake news* em relação ao COVID-19 [4].

Yang et. al (2020) estimaram a predominância de *links* para informações com baixa credibilidade no Twitter durante o surto e o papel dos *bots* na disseminação desses *links*. Os autores descobriram que o volume combinado de *tweets* com *links* para informações de baixa credibilidade é comparável ao volume de artigos do New York Times e *links* do CDC. Além disso, a análise de conteúdo revela uma politização da pandemia. A maior parte desse conteúdo se espalha por meio de retuítes. Os *bots* sociais estão envolvidos tanto na postagem quanto na amplificação de informações de baixa credibilidade, embora a maior parte do volume seja gerada por prováveis humanos [5].

Para o caso específico do Brasil, Garcia e Berton (2020) usaram a identificação de tópicos e a análise de sentimento para explorar um grande número de *tweets* no Brasil e nos EUA, que tiveram um alto número de propagação e mortes por COVID-19. Foram usados 3.332.565 *tweets* em inglês e 3.155.277 *tweets* em português para comparar e discutir a eficácia da identificação do tópico e da análise de sentimento em ambos os idiomas. O período analisado foi de abril a agosto de 2020 e os autores encontraram dez tópicos principais relacionados ao COVID-19 em ambos os idiomas, onde sete tópicos são equivalente como por exemplo: proliferação, tratamento e impacto econômico [3].

4 Tarefas

Para conseguir fazer a modelagem visual dos dados o trabalho será dividido em algumas etapas. Inicialmente será feita uma análise exploratória dos dados para compreender o comportamento, as principais características presentes e ter *insights* iniciais, como por exemplo, a distribuição de palavras chaves ao longo do tempo, e a distribuição da quantidade de *tweets* entre os perfis observados. Os dados disponibilizados pela Aos Fatos já foram previamente organizados e tratados, entretanto, alterações pontuais podem ser necessárias para a utilização. Em sequência, serão realizadas a modelagem de tópicos usando técnicas de *machine learning*.

Como desejamos avaliar a alteração do discurso ao longo do tempo, a nossa modelagem e visualização deverá desta forma, considerar o aspecto temporal. Considerando que cada *tweet* contém a informação da data de publicação, uma maneira simples de abordar tal problema seria utilizar um método de modelagem que não considera o tempo e após obter os tópicos, gerar a distribuição através da frequência de cada tópico nos *tweets* de diferentes intervalos de tempo. Demais técnicas de modelagem de tópicos para séries temporais também poderão ser consideradas. Para abordar o tempo na visualização, da mesma forma que a desenvolvida pelo *ConToVi*, utilizar de animações para representar os dados em diferentes momentos do tempo.

Por fim, para apresentar os resultados da modelagem de tópicos em diferentes intervalos de tempo, será representada visualmente a associação dos perfis e *tweets*, que poderão ser observados através da disposição espacial destes. Para permitir uma análise mais profunda, opções de interatividade serão adicionadas a visualização, como a exibição dos valores computados para *tweets* específicos e a relação com as palavras chave presentes neles.

5 Dados

Diariamente, jornalistas de Aos Fatos acompanham declarações de políticos e autoridades de expressão nacional, de diversas colorações partidárias, de modo a verificar a sua veracidade. As declarações são então classificadas com uma das sete categorias, dentre elas: Verdadeiro, Impreciso, Exagerado, Contraditório, Insustentável, Distorcido ou Falso.

6 Modelos

O principal modelo a ser considerado é o Latent Dirichlet Allocation (LDA), um dos mais populares atualmente. O LDA considera que cada para cada tópico existe uma distribuição de palavras e para cada texto existirá uma distribuição de tópicos. Dessa forma, teremos não somente a informação de qual tópico é o mais dominante em um texto, mas também a probabilidade de cada um dos tópicos, observando por exemplo se ela se concentra em um tópico específico, ou se possui valores altos para diferentes tópicos. Além disso, também poderemos interpretar o que cada tópico está representando através da sua distribuição de palavras.

7 Design

Baseado na visualização apresentada em [2], Figura 2, o nosso design será como na Figura 1, os tópicos serão representados em um circunferência externa, cada seção desta circunferência representando um tópico diferente, o comprimento deste tópico indicando a predominância dele. Internamente, representaremos os usuários através de círculos codificados pela cor, a cor representará a quantidade de retweets e likes que o usuário obteve. Estes pontos internos serão animados para representar a evolução da distribuição de usuários ao longo do tempo. Além dos círculos no centro da circunferência, estarão presentes sedimentos posicionados próximos aos tópicos, cada segmento representará um tweet distinto, codificado pela cor do usuário que o postou. Para compreender os resultados do modelo, implementaremos uma interatividade que quando o mouse estiver sobre um sedimento, surgirá um painel lateral apresentando o texto deste tweet e informações sobre a classificação de tópicos, como a probabilidade deste tweet pertencer a cada um dos tópicos.

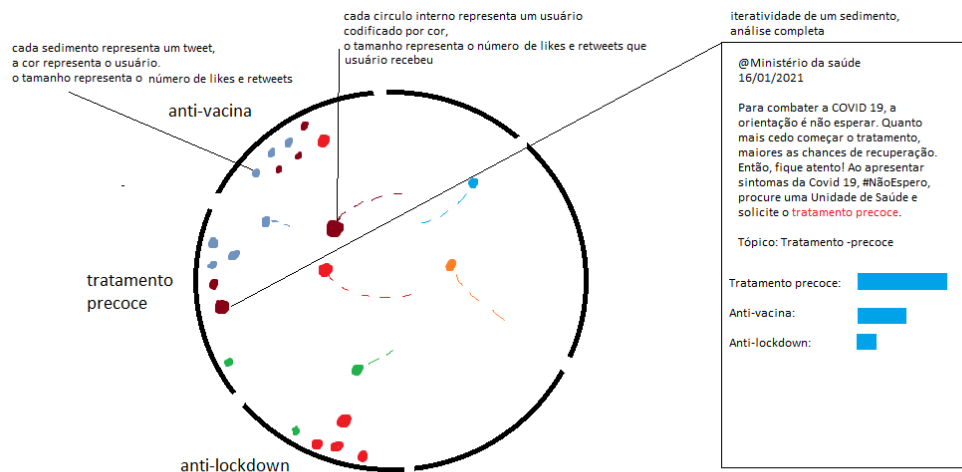


Figure 1: Design do objetivo da nossa visualização.




Figure 2: Visualização apresentada em ConToVi.

8 Etapas

- Análise exploratória, modelagem do tópicos e preparação para backend [Lucas]
- Círculo de tópicos e animação do posicionamento de participantes
- Sedimentos e interatividade dos sedimentos

References

- [1] Oberiri Destiny Apuke and Bahiyah Omar. Fake news and covid-19: modelling the predictors of fake news sharing among social media users. *Telematics and Informatics*, 56:101475, 2021.
- [2] Mennatallah El-Assady, Valentin Gold, Carmela Acevedo, Christopher Collins, and Daniel Keim. ConToVi: Multi-Party Conversation Exploration using Topic-Space Views. *Computer Graphics Forum*, 35(3):431–440, 2016.
- [3] Klaifer Garcia and Lilian Berton. Topic detection and sentiment analysis in twitter content related to covid-19 from brazil and the usa. *Applied Soft Computing*, 101:107057, 2021.
- [4] Andrea Moscadelli, Giuseppe Alбора, Massimiliano Alberto Biamonte, Duccio Giorgetti, Michele Innocenzio, Sonia Paoli, Chiara Lorini, Paolo Bonanni, and Guglielmo Bonaccorsi. Fake news and covid-19 in italy: Results of a quantitative observational study. *International Journal of Environmental Research and Public Health*, 17(16), 2020.

- [5] Kai-Cheng Yang, Christopher Torres-Lugo, and Filippo Menczer. Prevalence of low-credibility information on twitter during the COVID-19 outbreak. *CoRR*, abs/2004.14484, 2020.